

Introduction to Natural Language Processing

Jihoon Choi

2026.05.29

* This presentation is made based on Prof. Caren Han's Lecture

목차


- NLP란?
- 컴퓨터가 자연어를 이해하는 방법
- GPT와 Attention
- AI윤리

NLP란?

- NLP (Natural Language Processing); 자연어처리


NLP란 무엇인가요?

자연어 처리(NLP)는 머신 러닝을 사용하여 컴퓨터가 인간의 언어를 이해하고 소통하도록 돕는 인공 지능(AI)의 하위 분야입니다.

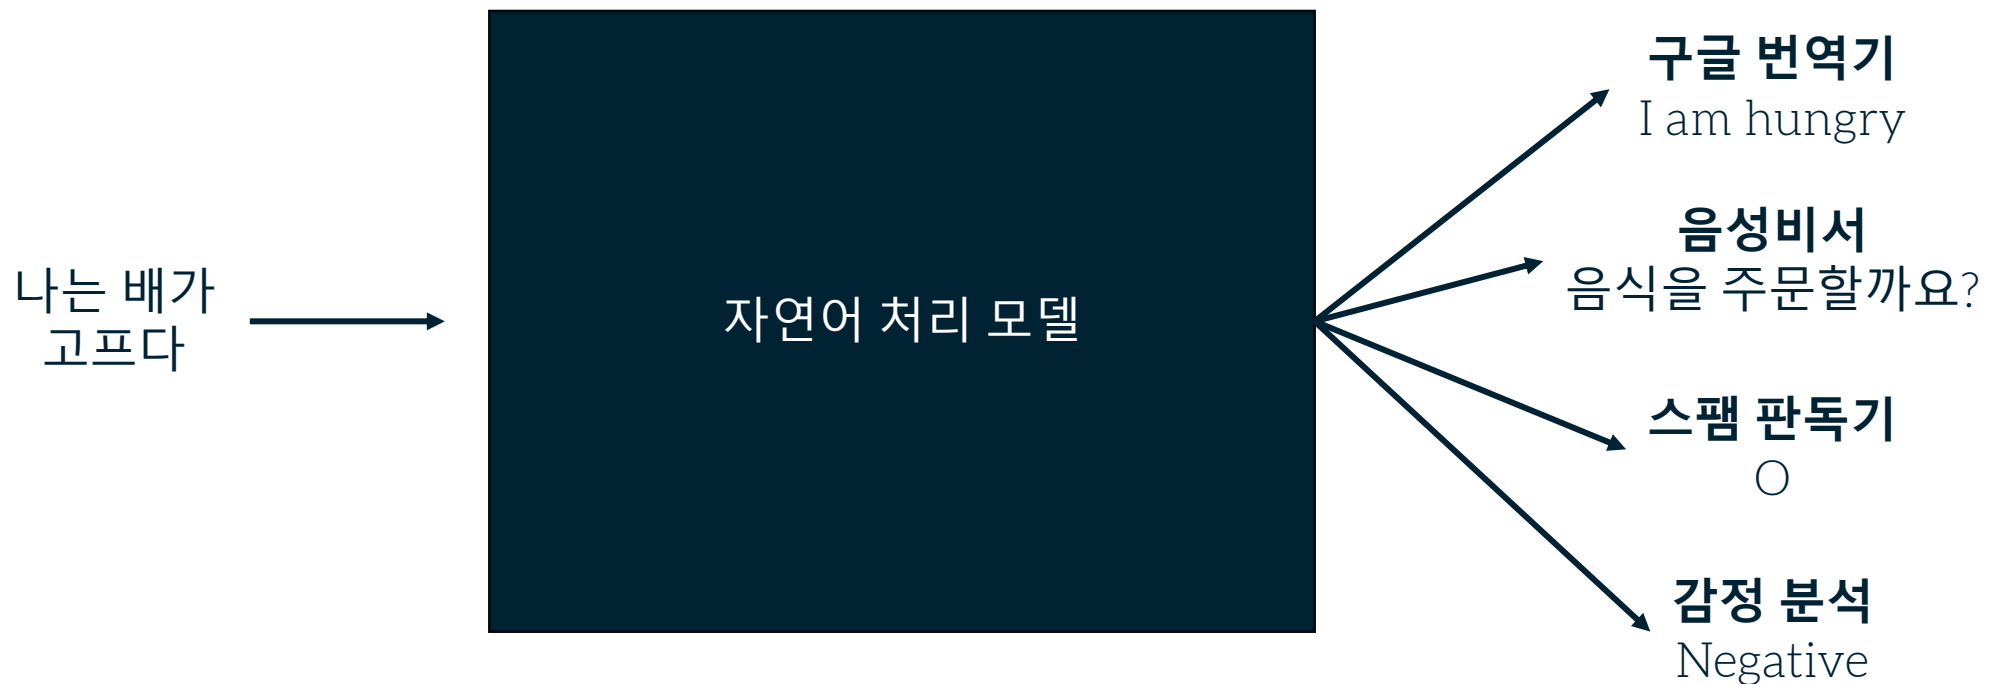


1. NLP란?

자연어 처리의 예시




자연어 처리의 과정



자연어를 숫자로 (Word Representation)


- 컴퓨터는 입력값을 숫자로 이해함.
- CNN에서 다뤘던 이미지 데이터도 이미지를 숫자로(RGB Scale)로 변환하여 입력되었음.



157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	93	17	110	210	180	154
180	180	50	14	94	5	10	93	48	106	159	181
206	100	5	124	191	111	120	204	166	15	56	180
194	68	137	251	237	299	299	228	227	87	71	201
172	106	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	105	35	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	85	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	254	211
183	202	237	145	0	0	12	108	209	138	243	236
196	206	123	207	177	121	123	200	175	13	96	218

One-Hot Encoding


- 전통적인 NLP에서 사용했던 기법
 - Hot (True, 1) Cold(False, 0)
- 단어를 one-hot vector로 나타낼 수 있음.




Vector dimension = number of words in vocabulary

One-Hot Encoding의 문제점?

- 문제 1. 단어간의 유사도를 측정할 방식이 없음.
- 예를 들어, london inn이라고 검색했을 때 우리는 london hotel도 함께 검색 되기를 원함.




- 문제 2. 비효율성
 - Vector dimension = number of vectors in vocabulary
 - 각 단어의 벡터 표현이 한 자리만 1이고 나머지는 0으로 채워져있음.



Bag of Words

- Bag of Words (BOW)
 - 문서 안에서 단어의 빈도를 설명하는 것.
 - 알려진 단어의 vocabulary
 - 단어의 존재 유무를 측정
- 문장 안에서 단어의 순서나 구조는 반영되지 않고, 오로지 빈도만 고려함.



Bag of Words



A vocabulary of known words

a	are	been	day	have	how	nice	see	to	you
---	-----	------	-----	------	-----	------	-----	----	-----

How are you	= [0, 1, 0, 0, 0, 1, 0, 0, 0, 1]
How have you been	= [0, 0, 1, 0, 1, 1, 0, 0, 0, 1]
Nice to see you	= [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
Have a nice day	= [1, 0, 0, 1, 1, 0, 1, 0, 0, 0]

Bag of Words

- 왜 BoW를 쓰는가?
 - 포함된 내용이 비슷하면 비슷한 콘텐츠라는 직관
 - 글의 내용(어떤 단어가 몇 번 쓰이는지)만으로도 의미를 어느정도 배울 수 있다
- BoW의 문제점
 - 글에서 단어가 등장하는 순서를 고려하지 않는다. 따라서 글 안에서의 단어가 갖는 의미, 즉 문맥을 무시하게 됨.
 - 예시: “this is interesting” vs. “is this interesting”

S1 = I love you but you hate me
S2 = I hate you but you love me



How to Represent the Word Similarity

- One-hot encoding
 - 단어간의 유사도를 평가하는 것이 어려웠음.
 - 또한, 단어의 개수가 늘어갈수록 차원이 높아지는 문제가 있음.




- 해결해야 할 문제
 - 더 낮은 차원으로 단어의 표현을 만들기
 - 단어의 유사도를 측정하기

정해진 벡터의 차원을 가지고 단어를 표현할 수 있을까? (Dense vector)


2. 컴퓨터가 자연어를 이해하는 방법

How to Represent the Word Similarity


- 어떻게 단어의 유사도를 표현할 것인가



Male-Female



Verb tense



Country-Capital

Word Algebra

Enter all three words, the first two, or the last two and see the words that result.


+ (-) =

korea 0.7751852795941121

2. 컴퓨터가 자연어를 이해하는 방법

Using Vectors to represent things

- 인격 검사를 한다고 가정
 - 개방성, 친화성, 성실성, 신경성, 외향성





Using Vectors to represent things

- 호날두와 박지성 중 메시와 성격이 더 유사한 사람은 누구인가?

코사인 유사도

두 벡터의 유사도를 측정하는 방법

$$\text{sim}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$





Using Vectors to represent things

- 호날두와 박지성 중 메시와 성격이 더 유사한 사람은 누구인가?

코사인 유사도

두 벡터의 유사도를 측정하는 방법

$$\text{sim}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$



$$\text{Cos}(\begin{bmatrix} 40 \\ 70 \end{bmatrix}, \begin{bmatrix} 30 \\ 20 \end{bmatrix}) \sim 0.89$$

$$\text{Cos}(\begin{bmatrix} 40 \\ 70 \end{bmatrix}, \begin{bmatrix} 40 \\ 60 \end{bmatrix}) \sim 0.99$$

2. 컴퓨터가 자연어를 이해하는 방법

Using Vectors to represent things

- 호날두와 박지성 중 메시와 성격이 더 유사한 사람은 누구인가?




개방성	친화성	성실성	신경성	외향성
40	70	50	20	10



30	20	30	70	20
----	----	----	----	----



40	60	40	30	50
----	----	----	----	----




이 벡터 표현(임베딩)을 통해

1. (성격을) 고정된 크기의 벡터로 나타낼 수 있고
2. 벡터간의 유사도를 쉽게 계산할 수 있게 됨.

Using Vectors to represent things

- 이걸 어떻게 단어에 적용시킬 수 있을까?
- Neural network를 이용해 dense vector를 학습!
- Word2Vec CBOW(Continuous Bag of Words)
 - 주변 단어를 보고 중심 단어를 예측
 - Sentence: "Sydney is the state capital of NSW"




Sequence Learning

- 앞에서는 단어의 벡터 표현을 만들어 내는 방법을 학습함.
- 그러나 실제 자연어 처리 문제에서는 단어 하나의 의미만이 중요한 것이 아니라, 단어가 등장하는 위치와 순서 또한 중요함.
- 어떻게 해야 AI모델이 순서와 위치를 이해하게 할 수 있을까?


Sequence Learning

- input이 한 번에 들어와서 처리가 되는 구조.
- boy is spreading을 연속적인 입력으로 보면 어떨까?
 - 시간의 개념을 더하는 것




Sequence Learning

- Concept




Sequence Learning

- Concept




Sequence Learning

- Speech Recognition




Sequence Learning

- Machine Translation




Sequence Learning

- Machine Translation




Seq2Seq Deep Learning

- Prediction




Seq2Seq Deep Learning

- Prediction + Memory




Seq2Seq Deep Learning

- Prediction + Memory




Seq2Seq Deep Learning

- Neural Network + Memory = Recurrent Neural Network




Seq2Seq Deep Learning

- Neural Network + Memory = Recurrent Neural Network




Seq2Seq Deep Learning

- Neural Network + Memory = Recurrent Neural Network




RNN

- 이 방식의 문제점
 - 입력과 다른 길이의 출력을 생성할 수 없음.
 - 번역과 같은 작업의 경우 전체 문장을 알아야 생성을 시작할 수 있음.
 - (+ 장기기억문제)



인코더-디코더 구조


- 인코더가 입력을 요약하고, 디코더가 생성하는 구조임.



2. 컴퓨터가 자연어를 이해하는 방법

인코더-디코더 구조

- 인코더가 입력을 요약하고, 디코더가 생성하는 구조임.




Attention!

+RNN의 단점:
장기기억의 부재

Attention with RNN


- 매 생성마다 input의 모든 값과 비교해서 중요한 부분을 얻어냄.



Attention with RNN


- 매 생성마다 input의 모든 값과 비교해서 중요한 부분을 얻어냄.

Sequence Model with Attention




Attention with RNN

- Attention을 통해 모든 state (입력)에 대한 접근이 가능한데 RNN 구조가 필요한가?
- 즉, recurrent model 자체가 필요한 것인가?



Transformer

- Attention 구조만 가진 Encoder-Decoder 모델



Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez*[†]
University of Toronto
aidan@cs.toronto.edu

Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin*[‡]
illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including

Figure 1: The Transformer - model architecture.

ChatGPT

- ChatGPT는 transformer를 핵심구조로 만들어져있음.
 - GPT는 이전 입력값을 보고 가장 확률이 높은 다음 단어를 뱉도록 학습됨.

User

Tell me about when Christopher Columbus came to the US in 2015

ChatGPT

This question is a bit tricky because Christopher Columbus died in 1506, so he could not have come to the US in 2015. But let's pretend for a moment that he did! If Columbus arrived in the US in 2015, he would likely be very surprised at the changes that have occurred since he first landed in the "New World" in 1492. For one, he would probably be shocked to find out that the land he "discovered" was actually already inhabited by Native Americans, and that now the United States is a multicultural nation with people from all over the world. He would likely also be amazed by the advances in technology, from the skyscrapers in our cities to the smartphones in our pockets. Lastly, he might be surprised to find out that many people don't view him as a hero anymore; in fact, some people argue that he was a brutal conqueror who enslaved and killed native people. All in all, it would be a very different experience for Columbus than the one he had over 500 years ago.

InstructGPT

Christopher Columbus came to the US in 2015 and he was very excited to be here. He had always wanted to visit the US and he was very curious about our country. He was very impressed with our country and he enjoyed his time here.


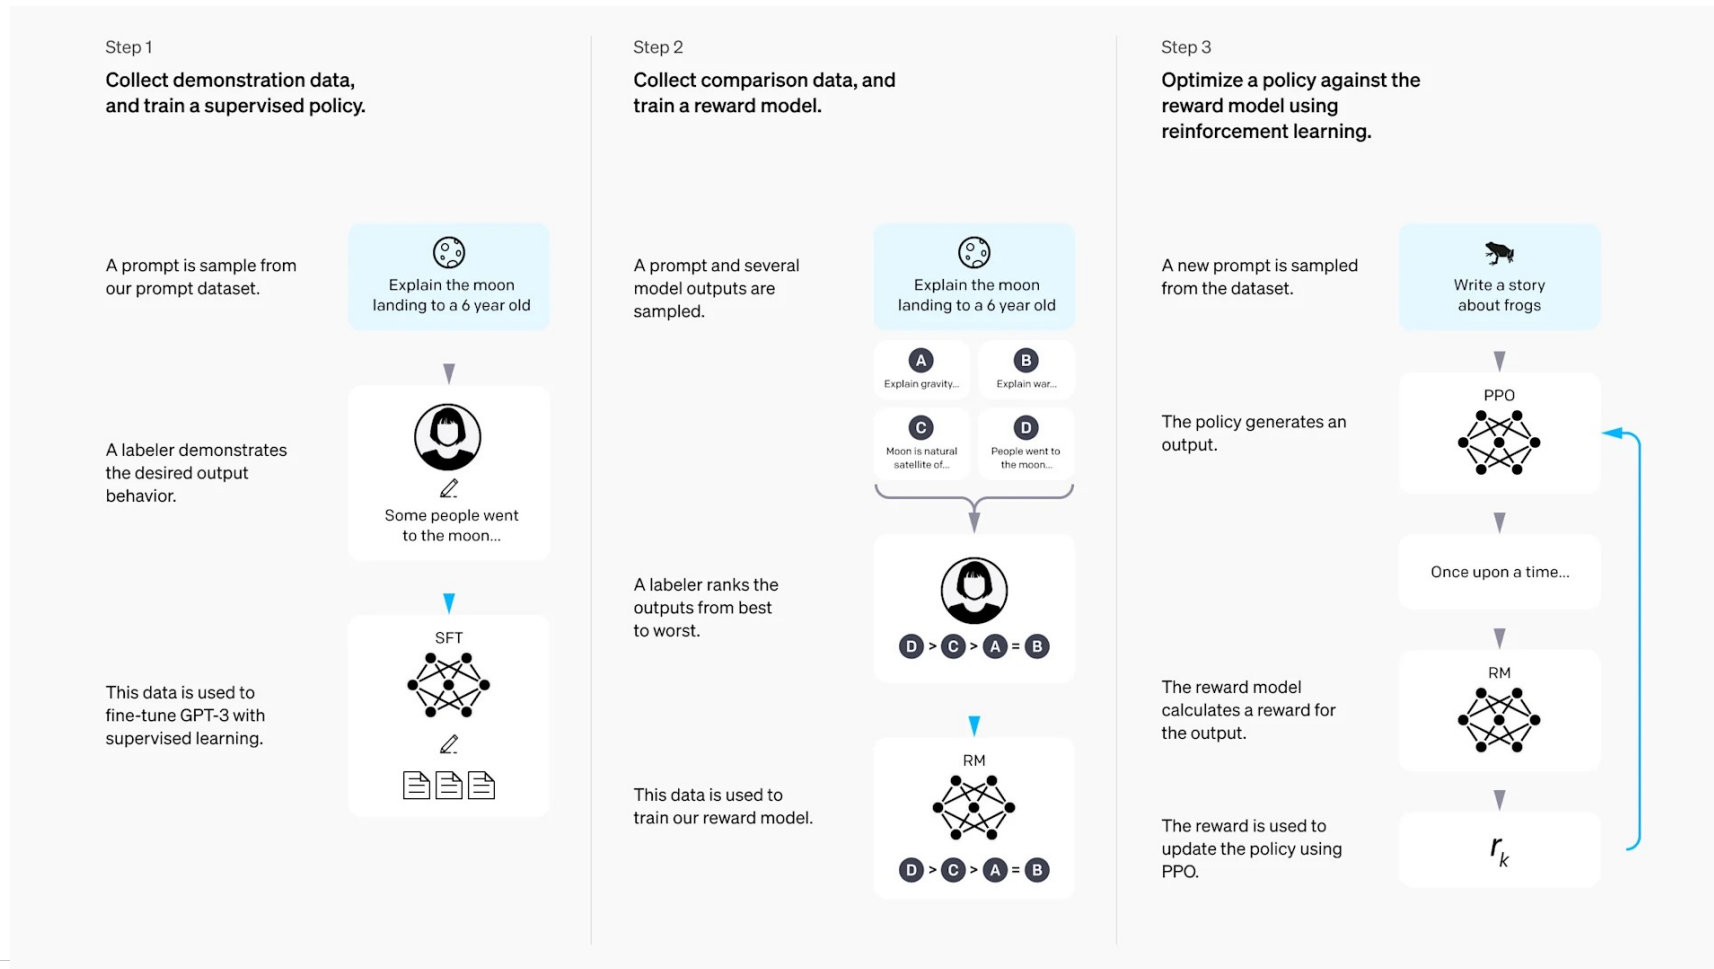


Figure 1: The Transformer - model architecture.

ChatGPT


- GPT가 사람과 유사하게 답을 뱉는 방법



Multimodal LLM (MLLM)

- ChatGPT는 이미지도 받고, 음성도 받지않나요?
- Multimodality
 - 텍스트, 이미지, 음성, 비디오와 같은 다양한 modality의 정보를 처리하고, 이해하고, 생성할 수 있는 능력

ChatGPT



2초 동안 생각함 >

구글(Google) 검색 홈페이지예요.

정확히는 크롬 새 탭/구글 시작 화면으로 보이고, 검색창에 "Google 검색 또는 URL 입력"이라고 되어 있어서 여기서 검색하거나 웹사이트 주소를 입력할 수 있습니다. 아래에는 웹 스토어, 네이버, 바로가기 추가 같은 바로가기 아이콘이 보입니다.

AI의 편향

- 공원에서 피크닉을 즐기는 사람들의 모습을 만들어줘.
- 생성 결과가 서양, 라틴계에 치중되어있음.



AI의 편향

- White washing
- 훈련데이터의 인종 불균형

